

《数据挖掘》课程项目个人工作总结

信管 2301 豆家晨 202321054009

在此次“基于多维度特征的劳动力 AI 替代风险挖掘与高危岗位识别”项目中我主要负责了全链路中的分类建模与 SHAP 可解释性分析这两个承上启下的核心模块。在分类建模阶段，为了在复杂的数据维度中精准定位替代风险，我构建并深入对比了 LightGBM、XGBoost 和 Random Forest 三种主流集成学习模型。经过严谨的交叉验证，LightGBM 模型表现最佳，以 40.72% 的准确率和 0.541 的 ROC-AUC 值胜出，最终被确立为最优预测模型。前期的探索性分析曾指出，所有数值特征与风险目标的相关系数极弱 ($|r| < 0.01$)，但在这种“信号微弱”的严苛挑战下，我们的模型依然越过了 0.5 的随机猜测线，成功捕捉到了隐藏在数据深处的非线性组合信号。这不仅验证了问题的可建模性，也为后续的深度归因打下了坚实基础。

在 SHAP 可解释性分析阶段，我重点剖析了模型的决策“黑盒”，真正做到了“知其然更知其所以然”。通过提取全局特征重要性排名，我发现目标编码后的岗位类别 (job_title_encoded) 是最具决定性的风险基准，其 SHAP 值约为 0.112，几乎是第二名特征的两倍。更重要的是，数据挖掘的价值在此刻得以凸显：“增长率×AI 冲击”与“薪资×远程”等交互特征在影响模型输出的 Top 10 特征中强势占据 4 席。这套分析体系清晰地向我们证明：所谓的高危岗位并非由低薪或低学历等单一标签决定，而是多重现实因素微弱叠加与复杂交互的结果。

课程致谢与感言：

课程将尽，落笔写下这份总结之际，心中最强烈的感受竟是深深的“相见恨晚”。作为一名信管专业的学生，我曾以为自己对数据流转与信息系统已有一点基础的认知，但直到真正走进老师的课堂，经历了这次与枯燥数据打交道，我才真正领略到这门学科潜藏在冰冷代码与复杂算法背后的无穷魅力。老师严谨求实的治学态度和毫无保留的真诚分享，像一盏明灯，一次次点透了在模型调优和逻辑归因时遭遇的迷雾。

由于大三这个特殊的时间节点，真的很遗憾没能在更早的时光里与这门课程相逢，未能更早地静下心来汲取老师所传授的智慧。但在探寻 AI 时代劳动力命运的这一次项目中，我学会了如何用 LightGBM 和 SHAP 去解构庞杂的数据指标，知道了如何用客观的分析框架去感受社会变迁的真实温度。这份由老师悉心浇灌出的、对数据挖掘之美的敬畏与热爱，将成为我未来专业道路上宝贵的底气。深深感谢老师的真诚与付出！