



南京工业大学

个人案例总结

班级：信管 2302

姓名：沈津亿

学号：202321059079

2026 年 6 月

南京工业大学经济与管理学院

一、项目背景与个人角色

人工智能技术快速发展。它正在改变全球劳动力市场。世界经济论坛预测，到2030年，全球约8500万岗位可能被机器取代。在这个背景下，我们团队开展了这个研究项目。项目的目标是系统性识别AI替代风险最高的岗位群组，揭示影响AI替代风险的多维特征交互效应。

我在项目中担任**数据准备与特征工程**的核心角色。我负责数据加载与质量评估、探索性数据分析（EDA）、特征工程构建（从13维扩展至37维），包括交互特征构造、目标编码、One-Hot编码、目标变量分箱处理及数据划分。我的工作为后续的分类建模、聚类分析和SHAP可解释性分析奠定了坚实的数据基础。

二、工作内容详细说明

（一）数据加载与质量评估

我首先加载了项目数据集。数据规模是30,000条岗位记录。原始特征有13个，分为5大维度：岗位属性、AI冲击、经济特征、工作特征、社会特征。

我进行了完整的数据质量评估。评估结果如下：

完整性：无缺失值，所有字段均为非空。

唯一性：无完全重复行。

一致性：数值字段类型正确，分类字段枚举值合理。

局限性：数据是模拟生成的，部分行业-岗位组合存在逻辑错配。

这一阶段的工作确保了后续分析的数据可靠性。

（二）探索性数据分析（EDA）

我负责了全面的探索性数据分析。这是理解数据特征分布和变量关系的关键步骤。

数值特征分布分析：

我分析了薪资、经验、岗位空缺数、远程工作比例、性别多样性等数值特征的分布。我发现数值特征分布相对平坦，没有哪个特征天然地集中在某个区间来区分高危和低危岗位。这意味着数据信号较弱，需要依赖多维特征交互和非线性模型。

分类特征与相关性分析：

我计算了所有数值特征与目标变量（Automation Risk）的相关系数。结果发现，所有相关系数绝对值都小于 0.01。Pearson（线性）和 Spearman（秩/单调）相关均极弱。我还使用 Kruskal-Wallis 检验，发现行业、地区、教育与风险无显著差异（ $p > 0.05$ ）。这些发现表明，单一特征无法有效预测 AI 替代风险，必须依赖多维特征交互和非线性模型。

分类特征与风险关系分析：

我分析了各行业、AI 冲击等级、学历等分类特征与风险的关系。我发现各行业的风险箱线图几乎完全重叠，中位数都在 50% 附近。所有分类变量的各类别下，低/中/高风险比例几乎一致（约 30%/30%/40%）。这进一步证实了从单维度看，无论是数值还是分类特征，都无法有效区分高危和低危岗位。

二维交叉分析：

我尝试了行业×AI 冲击、学历×趋势、地区×行业等二维交叉热力图分析。结果发现，三个热力图的单元格颜色差异极小（值均在 49-52 之间），没有高风险聚集区域。低学历+岗位缩减的直觉假设并不被数据支持。这启示我们，低维交叉分析无法捕捉数据的内在结构，必须依赖高维非线性模型自动发现模式。

高危 vs 低危对比分析：

我对比了高危和低危岗位的特征分布。KDE 曲线几乎完全重叠，说明高危岗位不是低薪、低经验、高远程的。增长率与风险呈云状散布，线性拟合斜率约 0。这说明岗位在增长不等于安全，缩减不等于 AI 替代。最终结论是：高危岗位是多特征组合的特定模式，而非单一特征极端值。

（三）特征工程（13 维→37 维）

这是我在项目中的核心贡献。基于 EDA 的发现，我设计了一套系统的特征工程策略，将原始 13 维特征扩展至 37 维。这包括以下四类特征构造：

1. 交互特征（9 个）—— 捕获特征间协同效应

我构造了 9 个交互特征，以捕获单变量分析中无法检测到的非线性组合效应。具体包括：

- 薪资×远程 (salary_remote)
- 增长×AI 冲击 (growth_impact)
- 薪资×经验 (salary_experience)
- 远程×增长 (remote_growth)

多样性×增长 (diversity_growth)
单位经验薪资 (salary_per_experience)
岗位密度 (job_density)
薪资标准化 (salary_zscore)
增长率 (growth_rate)

这些交互特征在后续的 SHAP 分析中被验证非常有效。例如，growth_impact_interaction 成为区分高危和低危的关键差异因子（SHAP 差 +0.032）。

2. 等级编码（4 个）—— 离散化捕获非线性阈值

我将连续变量离散化为等级特征，以捕获非线性阈值效应。具体包括：

experience_level（经验等级）
salary_level（薪资等级）
remote_level（远程等级）
growth_category（增长类别）

等级编码引入了领域知识驱动的离散化，有助于捕获阈值效应。

3. 有序编码（7 个）—— 分类变量自然顺序编码

我对有自然顺序的分类变量进行有序编码，保留顺序信息。具体包括：

education_encoded（1-5）
impact_encoded（1-3）
status_encoded（0/1）
industry_encoded 等

4. One-Hot 编码 & 目标编码（15 个）—— 哑变量+高信息编码

我对分类变量进行 One-Hot 编码，并创新性地使用了目标编码方法。具体包括：

Industry × 7 哑变量
Location × 7 哑变量
job_title_encoded（目标编码）：将 639 类岗位信息压缩为 1 个高信息量数值

目标编码的创新应用：

这是我在特征工程中的重要创新。原始数据中有 639 类不同的岗位名称（Job Title）。如果直接使用 One-Hot 编码，会产生 638 个哑变量，导致维度灾难。我采用了目标编码方法，将 639 类岗位映射为一个数值特征（job_title_encoded），这个数值是基于目标变量（Automation Risk）的均值编码。

后续分析证明，这个特征是模型最重要的特征。在 SHAP 全局重要性分析中，job_title_encoded 的 |SHAP| 值约为 0.112，是第二名（约 0.057）的近 2 倍。岗位类别成为最关键的 Risk 判别因子。

特征工程的核心价值：

交互特征：捕获单变量分析中无法检测到的非线性组合效应，后续 SHAP 验证其有效性。

目标编码：将 639 类岗位信息压缩为高信息量数值，成为模型最重要的特征（SHAP 排名第 1）。

等级编码：引入领域知识驱动的离散化，捕获阈值效应。

有序编码：类别本身有大小顺序，用 0/1/2/3... 保留顺序信息。

（四）目标变量分箱处理

我将连续的 Automation Risk (%) 目标变量（0-100%）进行分箱处理，转化为三分类问题：

Low Risk (0-30%)

Medium Risk (30-60%)

High Risk (60-100%)

分箱后的分布相对均衡：Low Risk 占 29.7%，Medium Risk 占 30.2%，High Risk 占 40.0%。这避免了严重的类别不平衡问题。

（五）数据划分

我将数据集划分为训练集和测试集。划分比例是 80% Train / 20% Test。这个划分比例为后续的模型训练、调参和评估提供了可靠的基础。

三、技术方法与工具

在我的工作中，我主要使用了以下技术方法和工具：

编程语言与库：

Python 3.x

pandas: 数据加载、清洗、转换

numpy: 数值计算

matplotlib / seaborn: 数据可视化（绘制箱线图、直方图、热力图、KDE 曲线等）

scikit-learn: 相关性分析、Kruskal-Wallis 检验、数据划分、目标编码

scipy: 统计检验

特征工程技术:

交互特征构造（多项式特征、乘积特征）

目标编码（Target Encoding）

One-Hot 编码

有序编码（Ordinal Encoding）

离散化与分箱（Binning）

Z-score 标准化

数据分析方法:

描述性统计分析（均值、中位数、标准差、偏度、峰度）

相关性分析（Pearson、Spearman）

非参数统计检验（Kruskal-Wallis 检验）

可视化分析（单变量分布、双变量关系、多变量交叉）

四、主要发现与贡献

通过系统的数据准备和特征工程工作，我取得了以下主要发现和贡献：

（一）关键发现

1. 数据信号微弱，需要多维交互建模

通过全面的 EDA，我发现了这个数据集的核心特点：所有数值特征与 Automation Risk 的相关系数绝对值都小于 0.01，分类特征各类别间风险差异极小。这意味着单一特征或低维交叉分析都无法有效区分高危和低危岗位。高危岗位是多特征组合的特定模式，而非单一特征极端值。这正是机器学习擅长但人眼难以发现的模式。

2. 交互特征是区分高危/低危的关键差异因子

我构造的 9 个交互特征在后续分析中发挥关键作用。SHAP 分析显示，growth_impact_interaction 是高危推力因子（+0.032），

salary_remote_interaction 是低危保护因子 (-0.032)。虽然交互特征在全局重要性中不如岗位名称 (job_title_encoded)，但在区分高危和低危的能力上最为关键。

3. 目标编码有效压缩高基数分类变量

我将 639 类岗位名称通过目标编码压缩为 1 个数值特征 (job_title_encoded)。后续分析证明，这个特征是模型最重要的特征，SHAP 全局重要性排名第 1 (|SHAP| 约 0.112)。这证明了目标编码在处理高基数分类变量时的有效性。

(二) 对项目的贡献

我的工作为整个项目奠定了坚实的数据基础，具体贡献如下：

1. 数据质量保障

通过系统的数据质量评估，我确保了后续分析的数据可靠性。我发现并记录了数据的局限性（模拟生成数据，部分行业-岗位组合存在逻辑错配），这为后续模型性能评估提供了重要背景。

2. EDA 揭示问题本质

我的 EDA 分析揭示了这个数据集的核心特点：数据信号微弱，需要多维交互建模。这一发现指导了后续的特征工程方向和模型选择。我们放弃了简单的线性模型，选择了能够捕获复杂非线性交互的集成学习模型 (LightGBM、XGBoost)。

3. 特征工程提升模型性能

我将原始 13 维特征扩展至 37 维，引入了交互特征、目标编码等创新方法。后续的模型对比显示，LightGBM 模型达到最佳 Accuracy (40.72%) 和 AUC (0.541)。虽然性能看起来不高，但考虑到数据信号微弱 (EDA 已证实单变量相关 $|r| < 0.01$)，这一结果实际上是合理且可解释的。性能不理想不是模型的问题，而是数据信号弱。

4. 为可解释性分析提供基础

我的特征工程作为后续的 SHAP 可解释性分析提供了丰富的特征空间。SHAP 分析成功识别了 job_title_encoded 是最关键的风险判别因子，交互特征是区分高危/低危的关键差异因子。这些发现为政策制定者和劳动者提供了有价值的决策支持。

五、遇到的挑战与解决方案

在工作过程中，我遇到了以下几个主要挑战：

（一）挑战 1：数据信号微弱，EDA 难以发现明显模式

问题描述：

在 EDA 阶段，我发现所有数值特征与 Automation Risk 的相关系数绝对值都小于 0.01，分类特征各类别间风险差异极小。传统的单变量分析和二维交叉分析都无法有效区分高危和低危岗位。

解决方案：

我没有放弃，而是系统地尝试了多种可视化方法和统计检验，包括箱线图、直方图、热力图、KDE 曲线、相关性分析、Kruskal-Wallis 检验等。通过全面的分析，我确认了数据信号微弱这一事实，并得出了“必须依赖多维特征交互和非线性模型”的结论。这一结论指导了后续的特征工程和模型选择。

收获：

我学会了在面对“负面结果”（没有显著模式）时，系统地记录和分析，将“没有发现”本身作为一个重要发现。这培养了我严谨的数据分析思维。

（二）挑战 2：高基数分类变量（639 类岗位）如何处理

问题描述：

原始数据中有 639 类不同的岗位名称（Job Title）。如果直接使用 One-Hot 编码，会产生 638 个哑变量，导致维度灾难，且大多数哑变量会非常稀疏。

解决方案：

我研究了一些高级编码方法，最终选择了目标编码（Target Encoding）。我将 639 类岗位映射为 1 个数值特征（job_title_encoded），这个数值是基于目标变量（Automation Risk）的均值编码。具体来说，对于每个岗位类别，我计算该类别下所有样本的 Automation Risk 均值，用这个均值作为该类别的编码值。

为了避免过拟合，我使用了交叉验证的目标编码方法（TargetEncoder from scikit-learn）。

结果验证：

后续的 SHAP 分析证明，`job_title_encoded` 是模型最重要的特征（|SHAP| 约 0.112，是第二名近 2 倍）。这验证了我选择目标编码方法的正确性。

收获：

我学会了根据数据特点选择合适的特征编码方法，而不是盲目使用默认的 One-Hot 编码。我也理解了高基数分类变量需要特殊处理。

（三）挑战 3：如何构造有效的交互特征

问题描述：

EDA 已证实单一特征无法有效预测 AI 替代风险。那么，如何构造能够有效捕获特征间协同效应的交互特征呢？

解决方案：

我基于领域知识和数据特点，系统地构造了 9 个交互特征。例如：

`growth_impact_interaction`（增长×AI 冲击）：** 捕获“岗位需求增长”和“AI 冲击等级”的交互效应。直觉是：一个岗位如果需求在增长，且 AI 冲击高，那么风险可能特别高（技术替代+岗位萎缩的双重压力）。

`salary_remote_interaction`（薪资×远程）：** 捕获“薪资水平”和“远程工作比例”的交互效应。直觉是：高薪资且高远程的岗位可能风险较低（因为技能稀缺且难以完全自动化）。

我不仅构造了交互特征，还在后续的 SHAP 分析中验证了其有效性。SHAP 分析显示，`growth_impact_interaction` 和 `salary_remote_interaction` 分别是高危推力因子和低危保护因子。

收获：

我学会了如何基于领域知识构造交互特征，并通过后续分析验证其有效性。这培养了我从数据到领域知识的综合能力。

六、个人成长与收获

通过这个项目，我在技术能力、分析问题能力、解决问题能力等方面都取得了显著成长。

（一）技术能力提升

1. 掌握了完整的数据挖掘流程

我从头到尾体验了数据挖掘的完整流程：数据加载→数据质量评估→探索性数据分析→特征工程→数据划分。这让我对数据挖掘有了更全面的理解。

2. 熟练使用了 Python 数据分析工具链

我熟练使用了 pandas、numpy、matplotlib、seaborn、scikit-learn 等 Python 库。我特别加深了对特征工程技术的理解，包括目标编码、交互特征构造、离散化与分箱等。

3. 学会了处理高基数分类变量

通过处理 639 类岗位名称这个高基数分类变量，我学会了目标编码等高级编码方法。这是我在该项目中学到的最有价值的技术之一。

（二）分析问题能力提升

1. 学会了系统地探索数据

在 EDA 阶段，我系统地探索了数值特征分布、分类特征分布、变量间相关性、二维交叉效应等。我学会了使用多种可视化方法和统计检验来全面理解数据。

2. 学会了从“负面结果”中提取价值

当我发现数据信号微弱、单变量相关极弱时，我没有简单地认为“这个数据没有用”。相反，我系统地记录了这些发现，并得出了“必须依赖多维特征交互和非线性模型”的结论。这培养了我严谨的数据分析思维。

3. 学会了将 EDA 发现指导后续分析

我将 EDA 的发现（数据信号微弱，需要多维交互建模）直接指导了后续的特征工程方向和模型选择。这让我理解了 EDA 不是孤立的步骤，而是整个数据挖掘流程的重要组成部分。

（三）解决问题能力提升

1. 学会了根据问题特点选择合适方法

面对高基数分类变量（639 类岗位），我没有盲目使用 One-Hot 编码，而是研究并选择了更适合的目标编码方法。这培养了我根据问题特点选择合适方法的能力。

2. 学会了迭代优化特征工程策略

我的特征工程策略不是一次成型的，而是迭代优化的。我首先尝试了交互特征，然后发现目标编码非常有效，接着又添加了等级编码和有序编码。通过迭代优化，我最终构造了一个 37 维的丰富特征空间。

3. 学会了验证自己的工作需要

我没有停留在“构造了特征”这一步，而是通过后续的 SHAP 分析验证了自己工作的有效性。当我发现 `job_title_encoded` 成为模型最重要的特征时，我感到非常欣慰。这培养了我“用结果验证工作”的习惯。

（四）对 AI 与就业关系的理解加深

通过这个项目，我对 AI 与就业的关系有了更深的理解：

1. AI 替代风险不是简单可判断的

我发现，高危岗位没有简单标签，不是低薪、低经验、高远程的岗位。高危岗位是多特征组合的特定模式（如 AI 高冲击+增长趋势+资深经验）。这让我理解了 AI 替代风险的复杂性。

2. 关键不是“会不会被替代”，而是“如何与 AI 协作”

项目的一个核心启示是：劳动者应该提升 AI 素养，培养跨领域复合能力，从“被替代的人”转变为“驾驭 AI 的人”。这对我自己的职业规划也有很大启发。

七、对信管专业同学的就业建议（基于本项目研究）

作为信息管理与信息系统专业的学生，我基于本项目的研究发现，对同专业同学的就业选择有以下建议：

（一）高危预警——这些信号要警惕

根据本研究，`job_title`（岗位类别）是最强风险预测因子（SHAP $\approx$ 0.112），岗位类别决定了近一半的风险判断。以下岗位要特别警惕：

- 纯靠 Excel/报表的数据助理
- 初级数据录入/清洗岗位
- 仅会复制模板的初级分析师
- 岗位名中含“助理”“专员”
- 所在行业已出现大规模 AI 工具替代迹象

（二）低危方向——发展这些核心能力

以下能力是 AI 难以替代的，应该重点发展：

系统分析与需求设计：理解业务逻辑，AI 难以替代。

数据治理与质量管理：需要领域知识+人工判断力。

AI 工具应用与集成开发：成为驾驭 AI 的人，而非被替代的人。

跨职能沟通与项目管理：信管专业天然的跨界优势。

（三）主动应对——三步转型策略

第一步：掌握可解释 AI 工具

例如本研究中使用的 SHAP+LightGBM。成为“懂 AI 的信管人”。

第二步：向人机协作方向定位

从“做分析”转向“定义分析框架”，从执行者变为协作设计者。

第三步：培养跨界复合能力

信息技术×业务领域双栖是护城河。

核心启示：

信管生的护城河不是专业本身，而是“懂技术+懂业务+能与 AI 协作”的复合能力。

八、项目局限性与未来改进方向

（一）项目局限性

1. 数据模拟性

数据是模拟生成的，部分行业-岗位组合存在逻辑错配，目标变量近似均匀分布。这限制了研究结论的现实适用性。

2. 特征维度有限

缺少任务复杂度、社交交互需求、创造力要求等关键特征。这些特征对于评估 AI 替代风险可能非常重要。

3. 模型预测力有限

LightGBM Accuracy 约 40.72%，AUC 约 0.54。这一性能虽然考虑到数据信号微弱是合理的，但确实限制了实际应用价值。模型更适合特征分析和风险排序，而非精确预测。

（二）未来改进方向

1. 引入真实职业数据库

融合 O*NET 等真实职业数据库，增加任务维度特征，使用 Frey & Osborne 框架进行交叉验证。

2. 增加文本分析

分析岗位描述文本，提取语义特征，构建文本风险评估模型。

3. 改进模型与特征

尝试深度学习（TabNet）、图神经网络、半监督/自监督学习等更强大的模型。

九、总结

通过这个项目，我系统掌握了数据挖掘的完整流程，特别是数据准备与特征工程的核心技术。我不仅学会了如何使用 Python 工具链进行数据分析，还学会了如何系统地探索数据、根据问题特点选择合适方法、迭代优化解决方案、用结果验证自己的工作。

我的主要贡献包括：（1）通过系统的 EDA 揭示了数据信号微弱的特点，指导了后续分析方向；（2）通过创新的特征工程（特别是目标编码和交互特征构造）将原始 13 维特征扩展至 37 维；（3）为后续的模型建模、聚类分析和 SHAP 可解释性分析奠定了坚实的数据基础。

最重要的是，通过这个项目，我对“数据科学不仅仅是跑模型，更是理解数据、理解问题、理解领域”有了更深的理解。这将指导我未来的学习和工作。

参考文献

本项目参考了以下文献和资源：

Frey, Carl Benedikt, and Michael A. Osborne. "The Future of Employment: How Susceptible Are Jobs to Computerisation?" *Technological Forecasting and Social Change*, vol. 114, 2017, pp. 254-280.

World Economic Forum. *The Future of Jobs Report 2023*. World Economic Forum, 2023, www.weforum.org/publications/the-future-of-jobs-report-2023/.

Lund, Susan, et al. "What's Driving the AI Revolution? Eight Charts Explain." *McKinsey Global Institute*, June 2018, www.mckinsey.com/featured-insights/artificial-intelligence/whats-driving-the-ai-revolution.

"ai_job_trends_dataset.csv." *Kaggle*, www.kaggle.com/datasets/.

声明:

本总结基于实际参与的数据挖掘课程项目撰写。所有技术方法、分析结果和结论均来自项目实际工作，无虚构内容。数据是模拟生成的（ai_job_trends_dataset.csv），研究结论的普适性存在局限。