

基于多维度特征的劳动力AI替代风险 挖掘与高危岗位识别

数据挖掘课程 · 小组案例报告

成员分工

沈津忆 数据准备与特征工程

豆家晨 分类建模与可解释性分析

陈绵山 (组长) 无监督挖掘 · PPT · 报告统筹

数据集: ai_job_trends_dataset.csv (30,000 条 × 13 特征)

分析框架: CRISP-DM 数据挖掘生命周期

目 录

一、研究背景与动机	第 3 页
二、数据集概况	第 4 页
三、探索性数据分析（EDA）	第 5 页
四、特征工程：从13维扩展至37维	第 6 页
五、分类建模与评估	第 8 页
六、聚类分析（无监督挖掘）	第 10 页
七、SHAP可解释性分析	第 12 页
八、关联规则挖掘	第 14 页
九、高危岗位识别与画像	第 15 页
十、对信管专业学生的就业建议	第 17 页
十一、政策建议	第 18 页
十二、研究局限与未来展望	第 19 页
十三、研究总结与附录	第 20 页

一、研究背景与动机

1.1 时代背景

随着人工智能技术的迅猛发展，全球劳动力市场正经历深层次的结构性变革。生成式AI、自动化流水线、智能决策系统持续渗透各行各业，对传统岗位产生深刻冲击。世界经济论坛（WEF）预测，到2030年全球约8500万个岗位将被机器取代，同时创造9700万个新岗位，但其中的技能错配、结构性失业与收入不平等问题不容忽视。

然而，现有研究中存在一个普遍的认知误区：人们倾向于将"工厂工人" "客服" "数据录入员"等直觉判断为高风险岗位，而将"医生" "律师" "工程师"标记为安全。本研究的核心价值在于通过数据挖掘方法检验并修正这一直觉——AI替代风险是否真的由行业、学历、薪资等单维因素决定？

1.2 研究问题

- 问题1：哪些岗位面临最高的AI替代风险？能否超越直觉，系统性地识别高危岗位群体？
- 问题2：什么决定了AI替代风险？是单一特征（如学历、行业）还是多维交互？
- 问题3：风险如何在劳动力群体中分布？是否存在某类群体天然安全或天然高危？

1.3 研究意义

层面	意义
学术层面	验证AI替代风险的多维交互机制，补充现有单维度研究的不足
政策层面	为政府劳动力转型政策提供数据驱动的决策依据
个人层面	帮助求职者和在职人员了解自身岗位的风险状况，制定主动应对策略

二、数据集概况

2.1 基本信息

项目	详情
数据规模	30,000 条记录，无缺失值，无重复行
原始特征数	13 个（经特征工程扩展至 37 个）
目标变量	Automation Risk (%), 范围 0–100%，近似均匀分布
岗位类型	639 种不同岗位名称
行业覆盖	8 类 (IT、Finance、Healthcare、Education、Retail、Manufacturing、Entertainment、Transportation)
地区覆盖	8 国 (USA、UK、Canada、Australia、Germany、India、China、Brazil)

2.2 特征维度总览

维度分类	特征说明
岗位属性	Job Title、Industry、Job Status (Increasing/Decreasing)
AI冲击指标	AI Impact Level (Low / Moderate / High)
经济特征	Median Salary (USD)、Job Openings (2024)、Projected Openings (2030)
工作特征	Experience Required (Years)、Remote Work Ratio (%)
社会特征	Gender Diversity (%), Location、Required Education

2.3 数据质量评估

数据整体质量较高（完整性100%，类型一致，枚举值合理）。但存在一项重要局限：数据为模拟生成，部分行业-岗位组合存在逻辑错配（如"Armed forces technical officer"出现在Entertainment行业、"Embryologist"出现在Manufacturing行业）。这一特性使得单变量统计关系偏弱，在解读结论时需保持理性。

三、探索性数据分析 (EDA)

3.1 目标变量分布：最关键的"第一发现"

统计量	值	解读
均值	50.15%	
中位数	50.02%	高度对称
标准差	28.75%	分布极扁平
偏度	0.004	近似均匀对称
峰度	-1.20	扁平，无明显集中趋势
Low (0-30%)	29.7%	
Medium (30-60%)	30.2%	三类占比接近均等
High (60-100%)	40.0%	

目标变量呈近似均匀分布，而非正态分布。三类风险占比高度均衡，各类别在特征空间中大量重叠，使分类任务天然困难。

3.2 单变量相关性分析：核心的"无信号"发现

□ 这是全篇最重要的EDA发现：任何单一特征都无法有效区分AI替代风险的高低。薪资高、学历高、AI冲击等级高——这些直觉上的高危/低危判断在数据中均无统计支持。

检验方法	结论
Pearson线性相关	所有数值特征 $ r < 0.01$ ，几乎无线性关系
Spearman秩相关	同样极弱，无显著单调关系
Kruskal-Wallis检验	分类特征（行业、地区、学历、AI冲击等级） $p > 0.05$ ，均不显著

3.3 高危与低危岗位初步画像对比

指标	高危岗位 (Risk > 80%)	低危岗位 (Risk < 20%)
样本量	6,003 (20.0%)	5,843 (19.5%)
均值薪资差异	与整体几乎一致	与整体几乎一致
行业分布	广泛覆盖全部8个行业	广泛覆盖全部8个行业
岗位覆盖	639类岗位中均存在高危样本	639类岗位中均存在低危样本

结论：没有任何行业或岗位是"天然安全"或"天然高危"的——同一个"Nurse"岗位，在不同特征组合下可以是高危也可以是低危。这直接导向了特征工程的必要性。

3.4 增长趋势与风险的悖论

岗位增长率与AI风险线性相关极弱 ($r = 0.003$)，各增长类别平均风险差异仅在49.5%–51.2%之间。存在"增长但仍高危"和"萎缩但低危"的结构性矛盾，说明岗位市场需求变化与AI替代风险并非简单的单向关系。

四、特征工程：从13维扩展至37维

4.1 为什么需要特征工程？

EDA已经证明：单个特征的信号极弱。要让模型学到有效规律，必须通过特征工程显式构造变量之间的交互关系，将隐藏在多维组合中的非线性信号提炼出来。

挑战	策略	新增特征数
特征间存在联合效应，单独无意义	构造交互特征	9个
连续变量的非线性阈值效应	等级编码（离散化）	4个
分类变量无法直接输入模型	有序/One-Hot编码	7个
岗位名称（639类）难以直接使用	目标编码	1个

4.2 九大交互特征详解

特征名	核心含义
growth_rate	岗位增长率 = (预测2030开放数 - 当前) / 当前，正=扩张，负=萎缩
salary_remote_interaction	薪资 × 远程比例 / 100，高薪且高远程 = 高自主性岗位综合指标
growth_impact_interaction	增长率 × AI冲击等级（Low=1, Mod=2, High=3），负值=萎缩+高冲击=最危险
salary_experience_interaction	薪资 × 经验年数，综合溢价效应
remote_growth_interaction	远程比例 × 增长率，远程趋势与市场增长的交互
diversity_growth_interaction	性别多样性 × 增长率，包容度与增长趋势交互
salary_per_experience	薪资 / (经验+1)，单位经验薪资（技能稀缺性指标）
job_density	当前开放数 / (经验+1)，岗位市场密度与经验门槛的比值
salary_zscore	(薪资 - 均值) / 标准差，跨行业标准化薪资水平

4.3 等级编码（离散化）

特征	分箱档位
experience_level	Entry(≤2年) / Junior(2–5年) / Mid(5–10年) / Senior(10–20年) / Expert(>20年)
salary_level	Low(<60K) / Med(60–90K) / High(90–120K) / VHigh(>120K)
remote_level	Low / Med / High / VHigh（四分位）
growth_category	SevereDecline / ModerateDecline / Stable / ModerateGrowth / HighGrowth

4.4 目标编码：最强特征的来源

job_title_encoded：将639种岗位名称映射为"该岗位类型的历史平均风险值"，将高维类别信息压缩为单一数值特征。后续SHAP分析证明，该特征的重要性（SHAP=0.112）是第二名（0.057）的近2倍，成为整个模型的最核心判断依据。

五、分类建模与评估

5.1 实验设置

配置项	说明
任务类型	三分类预测：Low Risk(0–30%) / Medium Risk(30–60%) / High Risk(60–100%)
数据划分	训练集80%（24,000条） / 测试集20%（6,000条），分层抽样
对比模型	LightGBM、XGBoost、Random Forest
评估指标	Accuracy、Macro Precision/Recall/F1、Weighted F1、ROC-AUC（One-vs-Rest）

5.2 三模型综合对比

模型	Accuracy	Macro F1	Weighted F1	ROC-AUC
LightGBM ★	40.72%	26.07%	29.11%	0.541
XGBoost	40.30%	23.94%	27.20%	0.535
Random Forest	40.08%	28.32%	31.03%	0.531
随机基准	33.3%	—	—	0.500

最终选择 LightGBM 作为主模型：Accuracy最高（40.72%）、ROC-AUC最高（0.541），且其基于梯度提升的分裂增益机制更适合捕捉交互特征的非线性贡献。

5.3 模型准确率偏低的深层原因

40.7%的准确率仅比随机猜测高7.4个百分点，这不是"失败的模型"，而是"数据本身信号弱"的客观反映。

层次	原因
数据层	目标变量近似均匀分布，三类别在特征空间中大量重叠
特征层	所有原始特征与目标的线性/非线性相关极弱，数据信噪比低
生成机制	模拟数据的风险标签可能含有不可预测的随机成分
任务层	三分类粒度细，中间"Medium"区间边界模糊，天然难以精确分类

5.4 超参数调优结果

参数	搜索范围	最优值
learning_rate	[0.05, 0.1]	0.1
max_depth	[6, 8]	8
min_child_samples	[20, 50]	50
num_leaves	[31, 63]	31
CV Macro F1	—	0.351（5折交叉验证）

5.5 LightGBM Gain特征重要性（Top 10）

排名	特征	Gain值	类型
1	job_title_encoded	5,126.5	目标编码（最强信号）
2	Gender Diversity (%)	1,898.6	原始特征
3	salary_remote_interaction	1,579.3	交互特征 ★
4	Remote Work Ratio (%)	1,503.6	原始特征
5	salary_per_experience	1,457.5	衍生特征
6	Job Openings (2024)	1,318.9	原始特征
7	salary_experience_interaction	1,314.1	交互特征 ★
8	Projected Openings (2030)	1,224.1	原始特征
9	growth_impact_interaction	1,200.4	交互特征 ★
10	job_density	1,127.8	衍生特征

Top 10 中交互特征占3席（第3、7、9名），验证了特征工程策略的有效性。

六、聚类分析（无监督挖掘）

6.1 K值论证：三指标交叉验证

指标	方法说明	结论
肘部法（Elbow）	绘制 Inertia-K 曲线，寻找下降拐点	K=4时出现明显弯曲
轮廓系数（Silhouette）	衡量簇内紧密度与簇间分离度	K=4时达到局部最优
CH指数（Calinski-Harabasz）	衡量簇间方差与簇内方差之比	K=4时综合评分良好

三指标一致指向 K=4 为最优聚类数。

6.2 模型选择：K-Means vs GMM

对比维度	K-Means	GMM（高斯混合模型）
分配方式	硬划分（唯一归属）	软分配（概率归属）
形状假设	球形、凸形簇	椭圆形，可捕捉协方差结构
参数选择	K值（轮廓系数+肘部法）	n_components（BIC/AIC，最优n=7）
Silhouette对比	更高（最终采用）	略低
使用结论	主要方法，输出最终结果	对照方法，验证K-Means稳健性

6.3 K-Means聚类结果：四群体画像

指标	Cluster 0	Cluster 1	Cluster 2	Cluster 3
样本量	11,045（36.8%）	12,428（41.4%）	732（2.4%）	5,795（19.3%）
均薪(USD)	\$118,978	\$58,978	\$90,116	\$101,906
经验(年)	13.22	11.01	10.19	1.95
远程比例(%)	52.4%	47.2%	53.4%	50.2%
性别多样性(%)	50.2%	49.8%	50.1%	50.1%
风险均值(%)	50.4%	50.2%	50.7%	49.6%
画像标签	高薪·资深	低薪·主力	IT偏重·小众	高薪·新手

❏ 最重要的发现：四个聚类的风险均值集中在49.6%–50.7%，差异仅1.1个百分点。聚类主要按薪资和经验（经济/职业特征）分群，而非AI替代风险。AI替代风险是跨越经济结构层级的普遍性风险，而非某一特定群体的专属威胁。

6.4 降维可视化

采用PCA（主成分分析）将37维数据压缩至2D进行空间分布可视化；同时在5000条随机抽样数据上进行t-SNE非线性降维（perplexity=30, max_iter=1000），展示局部邻域结构。两种降维结果均显示：高危/低危样本在特征空间中呈弥散分布，无清晰的风险聚集结构，进一步印证“风险无特定分布区域”的结论。

七、SHAP可解释性分析

7.1 方法概述

采用 SHAP TreeExplainer（基于Shapley值的博弈论框架，专为树模型设计）对LightGBM进行全局与局部可解释性分析。处理三分类的3D SHAP值矩阵（每条样本 × 每个特征 × 每个类别），分别计算High Risk类和Low Risk类的特征贡献，并对比高危与低危岗位的SHAP值差异。

7.2 全局特征重要性 (Top 10, 按平均|SHAP|)

排名	特征	平均 SHAP	解释
1	job_title_encoded	0.1115	岗位类别——最关键判别因子
2	growth_impact_interaction	0.0573	增长×AI冲击联合效应
3	Gender Diversity (%)	0.0528	性别多样性
4	Projected Openings (2030)	0.0478	未来岗位预测数
5	salary_remote_interaction	0.0475	薪资×远程交互
6	salary_experience_interaction	0.0448	薪资×经验交互
7	remote_growth_interaction	0.0448	远程×增长交互
8	Job Openings (2024)	0.0440	当前岗位空缺数
9	Remote Work Ratio (%)	0.0427	远程工作比例
10	diversity_growth_interaction	0.0414	多样性×增长交互

job_title_encoded (0.112) 是第二名的近2倍；Top10中交互特征占4席；原始薪资排第15 (SHAP=0.036)，学历排第17 (SHAP=0.015) ——印证EDA弱相关结论。

7.3 高危 vs 低危岗位的SHAP对比

特征	高危SHAP	低危SHAP	差值	方向
growth_impact_interaction	0.076	0.044	+0.032	推高风险 ↑
remote_growth_interaction	0.062	0.045	+0.017	推高风险 ↑
salary_experience_interaction	0.051	0.038	+0.012	推高风险 ↑
job_title_encoded	0.155	0.147	+0.008	推高风险 ↑
salary_remote_interaction	0.038	0.070	-0.032	降低风险 ↓ (最强保护)
Remote Work Ratio (%)	0.035	0.052	-0.017	降低风险 ↓
Gender Diversity (%)	0.041	0.056	-0.016	降低风险 ↓
Projected Openings (2030)	0.045	0.057	-0.012	降低风险 ↓

7.4 SHAP核心洞察 (四点)

- 交互特征是风险判别的核心机制：最强的"推力"和"保护"因子都来自交互特征，而非任何单一原始特征

- 同一特征在不同场景贡献截然不同：growth_impact_interaction在高危样本贡献+0.085，低危样本仅+0.002
- AI Impact Level的"悖论"：单独看时SHAP仅0.010，必须与增长率组合才产生显著效应
- 高薪×高远程 = 最强低危保护：salary_remote_interaction是唯一能显著降低风险的交互组合

八、关联规则挖掘

8.1 事务数据构建（9个离散化维度）

维度	离散化标签
风险等级	Risk_Low / Risk_Medium / Risk_High（按0-30-60-100分箱）
薪资等级	Salary_Low / Med / High / VHigh（4等分位）
经验等级	Exp_Entry / Junior / Mid / Senior / Expert（5职业阶段）
远程比例	Remote_Low / Med / High / VHigh（4分位）
性别多样性	Diversity_Low / Med / High / VHigh（4分位）
岗位增长	Growth_Inc / Growth_Dec（二分）
AI冲击	AI_Low / Moderate / High（三级）
教育程度	保持原始5级类别值
行业	保持原始8类行业值

8.2 算法参数与挖掘结果

参数	设置值	说明
最小支持度（min_support）	0.05	规则至少覆盖5%的事务
最小置信度（min_confidence）	0.30	规则至少有30%预测准确率
最大项集长度	4	避免组合爆炸
频繁项集总数	415	—
关联规则总数	384	—
高危风险相关规则	93条	后件含Risk_High

8.3 高危风险关联规则 Top 10（按Lift排序）

#	前件（Antecedent）	支持度	置信度	Lift
1	Growth_Inc + Remote_High	5.04%	41.13%	1.028
2	Diversity_VHigh + Growth_Inc	5.14%	40.96%	1.023
3	AI_High + Exp_Senior	6.50%	40.92%	1.022
4	Growth_Inc + Salary_VHigh	5.05%	40.91%	1.022
5	Diversity_Low + Growth_Dec	5.04%	40.78%	1.019
6	Finance（行业）	5.06%	40.80%	1.019
7	Remote_High	9.99%	40.82%	1.019
8	Salary_VHigh	10.01%	40.72%	1.017
9	AI_High	13.45%	40.33%	1.008

#	前件 (Antecedent)	支持度	置信度	Lift
10	AI_Low	13.02%	39.27%	0.981

□ 关键发现：所有高危规则Lift集中在0.98–1.03，最高仅1.028。Lift=1.0意味着特征与高危风险相互独立，没有任何特征组合是高危风险的可靠"标志"——AI替代风险需要多维交互综合判断。

对比组合规则（Lift=1.028）与单变量规则（AI_High, Lift=1.008）：前者略优，证明特征交互效应存在，但整体强度极弱，与SHAP分析相互印证。

九、高危岗位识别与画像

9.1 模型预测高危概率 Top 20 岗位

排名	岗位名称	行业	AI冲击	薪资(USD)	实际风险	预测概率
1	Environmental manager	Finance	High	\$144,378	79.1%	92.0%
2	Editor, magazine features	Entertainment	Low	\$78,296	71.3%	88.2%
3	Senior tax professional	Finance	Moderate	\$145,532	68.1%	87.0%
4	Civil Service fast streamer	Retail	Low	\$35,088	70.3%	86.9%
5	Armed forces tech officer	Entertainment	Moderate	\$146,169	95.1%	86.6%
6	Land/geomatics surveyor	Education	Moderate	\$92,882	70.8%	86.1%
7	Electronics engineer	Finance	High	\$135,528	91.3%	85.9%
8	Licensed conveyancer	Transportation	Moderate	\$96,690	67.1%	85.2%
9	Media buyer	Retail	High	\$144,048	91.4%	84.9%
10	Health service manager	Entertainment	High	\$142,708	71.1%	84.8%
11	Embryologist, clinical	Manufacturing	Low	\$144,486	94.2%	84.4%
12	Product designer	IT	High	\$138,100	79.2%	84.1%
13	Loss adjuster, chartered	Healthcare	Moderate	\$54,463	88.1%	84.0%
14	Dancer	Entertainment	High	\$145,643	71.2%	83.8%
15	Corporate treasurer	Entertainment	High	\$107,190	79.1%	83.4%
16	Surveyor, building control	Healthcare	High	\$131,001	64.3%	83.3%
17	Legal executive	Transportation	Low	\$132,133	92.5%	83.2%
18	Sales executive	Finance	High	\$147,823	64.9%	83.1%
19	Science writer	Finance	High	\$138,329	97.0%	83.1%
20	Housing manager/officer	Education	Low	\$149,430	99.1%	82.9%

注意：列表中出现了"Embryologist, clinical" (AI冲击=Low)、"Legal executive" (AI冲击=Low) 等直觉上"安全"的高技能岗位被判定为高危，颠覆了"AI冲击等级=风险等级"的简单直觉。

9.2 四类高危岗位典型画像

画像一： "增长×高AI冲击"型

代表岗位： Electronics engineer (Finance/AI High)、Media buyer (Retail/AI High)

特征组合： AI Impact = High + Growth_Inc/Dec + experience_level = Senior

风险机制： AI技术直接冲击工作内容，行业扩张伴随自动化投入加大

画像二： "萎缩+高远程+低薪"型

代表岗位： Civil Service fast streamer (薪资\$35K)

特征组合： Salary_Low + Remote_High/VHigh + Growth_Dec

风险机制：低薪+高可远程化=高可替代性，岗位萎缩叠加AI成本优势

画像三： "特定行业+低技能门槛"型

代表岗位： Armed forces technical officer (Entertainment/High School)

特征组合： Industry = Entertainment/Transportation + Education = High School/Associate

风险机制： 高度标准化的任务内容+低技能壁垒=高自动化潜力

画像四： "三重叠加"最危险型

特征组合： Growth_Dec + AI_High + Exp_Entry/Junior

风险机制： 需求端萎缩（岗位在减少）+ 供给端冲击（AI直接替代）+ 替代成本低（入门级）→ 三重打击

9.3 高危岗位四层识别框架

层级	特征	SHAP值	作用
一级	job_title_encoded	0.112	决定风险基准（岗位类型本身）
二级	growth_impact_interaction	0.057	调节风险方向（萎缩×高冲击=危险）
三级	salary_remote_interaction	0.048	调节风险强度（高薪×高远程=保护）
四级	Projected Openings(2030) / job_density	0.040	补充修正因子

十、对信管专业学生的就业建议

10.1 研究对信管生的直接启示

□ AI替代风险没有「安全群体」——高薪资深群体与低薪入门群体的平均风险几乎一致，学历的保护效应极弱（SHAP=0.015），行业更不是防火墙（所有行业均存在高危岗位）。专业名称不等于就业保障，决定职业风险的是你承担的具体工作任务内容。

10.2 高危预警：哪些路径要警惕

高危信号	具体表现	数据支撑
纯数据录入/整理	只会Excel操作，依赖数据填报	Exp_Entry + AI_High路径，三重高危组合
固化模板执行者	按既定SOP完成报表，缺乏分析判断	job_density高 + growth_impact负值
行政辅助型数据岗	薪资低+远程比例高+岗位萎缩	salary_remote组合在低危侧保护失效
单一技能依赖	仅会某一特定软件/工具，无迁移能力	job_title_encoded单一化→高危

10.3 低危方向：信管生的护城河

方向	岗位举例	核心壁垒
系统分析与设计	系统分析师、业务架构师	跨领域沟通+抽象建模能力，AI难以替代
数据治理与质量管理	数据治理专员、元数据管理	涉及人际协调+组织流程，高社交交互需求
AI工具集成与管理	AI产品经理、RPA项目负责人	懂技术+懂业务+驾驭AI工具的复合能力
数据分析决策支持	高级业务分析师、数据产品经理	从"产出数据"到"定义分析框架"的升级

10.4 主动应对策略：三步转型路径

第一步：掌握可解释AI工具（1年内）

学习SHAP、LightGBM等可解释性工具，从"使用Excel"升级到"构建与解释模型"。目标：不只是数据的消费者，而是数据洞察的生产者。

第二步：从执行者转向「协作设计者」（1-3年）

不是"帮AI调参数"，而是"定义什么问题值得用AI解决"。培养业务理解能力：用数据语言翻译业务问题，用业务逻辑解释模型结果。

第三步：构建「技术×业务×沟通」复合能力（长期）

技术：Python/SQL/可视化+机器学习基础；业务：深入理解1-2个垂直领域（如金融、医疗、制造）；沟通：将复杂分析结论用非技术人员能理解的语言呈现——这是AI目前最难复制的能力。

十一、政策建议

11.1 短期措施（0-12个月）

措施	具体内容	目标群体
高危岗位预警机制	基于37维特征框架建立风险评分仪表盘，对预测高危概率>80%的岗位发出预警	政府劳动部门
技能转型试点	优先针对Entertainment、Transportation行业，设计"AI+人"协同工作模式培训	高危行业从业者
AI素养培训补贴	对高危岗位从业者提供免费AI素养培训，目标覆盖高危从业者的30%	在职人员

11.2 中期措施（1-3年）

- 开发岗位风险评估在线工具：帮助求职者按岗位名称、行业、薪资范围查询风险等级和个性化建议
- 建立"行业-政府-教育"三方协作体系：行业提供岗位变化数据→政府提供政策支持→教育机构设计再培训课程
- 高危地区就业转型服务中心：提供职业咨询、技能评估、再就业对接一站式服务

11.3 长期措施（3-5年）

- 劳动力市场AI影响动态监测平台：实时跟踪AI对不同岗位的影响，发布年度《AI与就业影响白皮书》
- 推动教育体系改革：高等教育增设"人机协作"课程，强化AI不可替代能力（创造力、同理心、复杂决策）
- 社会保障缓冲机制：研究针对AI替代导致结构性失业的保障方案，探索AI税收-再分配机制

11.4 面向不同群体的差异化建议

目标群体	核心建议
政策制定者	关注风险的普遍性，避免仅聚焦特定"高危行业"；建立动态监测体系；重视"增长但仍高危"的结构性矛盾
教育机构	强化软技能和AI素养教育；减少对易自动化技能的过度投入；引入人机协作课程模块
企业	主动推进"AI+人"协同模式；投资员工再培训；尤其关注高危岗位员工的主动转型支持
劳动者	主动提升AI素养；关注自身岗位的特征组合风险（而非单纯行业/薪资判断）；培养跨领域复合能力

十二、研究局限与未来展望

12.1 研究局限

局限类型	具体说明
数据模拟性	数据为模拟生成，行业-岗位存在逻辑错配，目标变量近似均匀分布与真实市场可能存在差异
特征维度有限	缺少任务复杂度、社交交互需求、创造力要求等关键特征；缺少岗位文本描述；缺少历史时序数据
预测能力有限	LightGBM准确率40.7%，Macro F1仅0.26，ROC-AUC约0.54；更适合作为特征分析工具而非精确预测工具
关联强度弱	全部关联规则Lift值接近1.0，无法得出"某特征组合导致高危"的因果性结论
因果推断缺失	本研究为关联性分析；SHAP值反映特征对模型预测的贡献，而非对风险本身的因果效应

12.2 未来研究方向

1. 引入真实职业数据库：融合O*NET等权威数据，增加任务维度特征（Routine程度、Social Intelligence需求），与Frey & Osborne（2013）框架交叉验证
2. NLP文本挖掘：融合岗位描述文本，提取任务复杂度、创新性要求、人际交互频率等语义特征，构建基于文本的风险评估模型
3. 时序动态建模：追踪AI技术进步（如大语言模型、多模态模型推出时间节点）对不同岗位风险的动态影响
4. 因果推断方法：采用双重差分（DID）、工具变量法（IV）等方法替代纯关联分析，利用自然实验建立因果关系
5. 深度学习扩展：尝试TabNet、深度森林等表格数据深度学习方法；探索GNN建模岗位间的职业迁移关系
6. 交互式决策支持系统：开发面向公众的在线风险查询工具，支持按行业/地区/岗位名称查询，提供个性化职业转型建议

十三、研究总结

13.1 五大核心发现

#	核心发现	方法支撑
1	AI替代风险无"天然安全行业": 各行业、各学历、各薪资水平的平均风险均在50%左右	EDA、聚类分析
2	单变量无法预测风险: 所有原始特征与目标变量的线性/非线性相关极弱 ($ r < 0.01$, 均 $p > 0.05$)	Pearson / Spearman / Kruskal-Wallis
3	交互特征是判别核心: 构造的交互特征 (growth_impact_interaction、salary_remote_interaction) 是最强的风险推力和保护因子	LightGBM Gain、SHAP
4	聚类揭示经济结构, 而非风险结构: K=4聚类主要按薪资+经验分群, 四群体风险均值差异仅1.1个百分点	K-Means聚类
5	最危险组合: "技能门槛低+岗位萎缩+AI高冲击"三重叠加, 是关联规则与SHAP共同指向的最显著高危画像	Apriori关联规则、SHAP对比

13.2 研究贡献

贡献类型	说明
方法论贡献	构建了"EDA→特征工程→分类建模→聚类→SHAP→关联规则"的完整数据挖掘流程, 各方法形成互证体系
认知贡献	量化证明了"AI替代风险是多维交互结果而非单因素决定", 修正了基于直觉的简单化判断
工具贡献	形成了可复用的高危岗位四层识别框架 (岗位类别→增长×冲击→薪资×远程→岗位密度), 具有推广应用价值

13.3 小组成员分工

成员	主要职责	主要产出
沈津忆	数据准备 + 特征工程	数据清洗、EDA分析、13维→37维特征构造 (含9个交互特征、4个等级特征、目标编码)
豆家晨	分类建模 + 可解释性	LightGBM/XGBoost/RF三模型对比、超参数调优、SHAP TreeExplainer全局与局部分析
陈绵山 (组长)	无监督挖掘 + 统筹	K值三指标论证、K-Means vs GMM对比、聚类画像雷达图、Apriori关联规则挖掘、报告整合、PPT制作
前期协作	三人共同参与	研究框架设计、数据探索、特征工程前期调研

附录：关键评估指标汇总

指标	数值	背景说明
LightGBM Accuracy	40.72%	三分类, 高于随机基准33.3%
LightGBM ROC-AUC	0.541	One-vs-Rest

指标	数值	背景说明
GMM最优分量数	7	基于BIC准则
SHAP Top1特征重要性	0.1115 (job_title_encoded)	第二名的近2倍
关联规则最高Lift	1.028	所有高危规则Lift≈1.0，强度极弱
高危相关规则总数	93条	后件含Risk_High

本报告由三人小组协作完成，数据挖掘课程结业项目。研究基于模拟数据集，结论仅反映数据内部规律，不构成真实劳动力市场的因果判断。